

Trabajo Fin de Máster

MODELO INTELIGENTE PARA EL ANÁLISIS DE LA SATISFACCIÓN DEL CLIENTE Y LA RECOMENDACIÓN DE RESTAURANTES A PARTIR DE RESEÑAS GASTRONÓMICAS EN PERÚ



**UNIVERSIDAD
COMPLUTENSE**
MADRID

Máster en Data Science, Big Data y Business Analytics

Alumno: Miguel Ángel Chávez Calle

Universidad: Universidad Complutense de Madrid

Año: 2026

Contenido

1.	Resumen Ejecutivo	3
2.	Introducción	3
2.1.1.	Problema de negocio.....	3
3.	Objetivos	4
3.1.1.	Objetivo General	4
3.1.2.	Objetivos Específicos.....	4
4.	Hipótesis.....	4
4.1.1.	Hipótesis General	4
4.1.2.	Hipótesis Específicas	4
5.	Procedencia del conjunto de datos.....	4
6.	Metodología de desarrollo.....	5
6.1.	Preparación de Datos y Análisis Exploratorio	5
6.2.	Análisis de sentimientos y aspectos.....	6
6.2.1.	Sentimiento mediante NLP	6
6.2.2.	Análisis de aspectos.....	6
6.3.	Modelización y mejoras del modelo	7
6.3.1.	Definición de la variable objetivo.....	8
6.3.2.	Preparación de datos para el modelo	8
6.3.3.	Modelo Inicial.....	9
6.3.4.	Comparación de alternativas	9
6.3.5.	Optimización y mejoras introducidas.....	10
6.3.6.	Modelo Final Seleccionado	11
6.3.7.	Inferencia sobre nuevas reseñas.....	12
7.	Resultados e interpretación del negocio	12
8.	Aplicación Empresarial	16
9.	Conclusiones.....	18
10.	Anexos.....	19
10.1.	Código fuente y material de desarrollo.....	19

1. Resumen Ejecutivo

El presente Trabajo Fin de Master desarrolla una solución analítica orientada a comprender y clasificar la satisfacción de clientes de restaurantes peruanos a partir de **reseñas (Reviews)** publicadas en plataformas digitales. El enfoque final prioriza la interpretación empresarial ya que permite convertir miles de comentarios no estructurados en indicadores de satisfacción, factores de experiencia y recomendaciones utilizables para la toma de decisiones.

Tras la depuración del conjunto de datos se trabajó con **569,102** reseñas válidas para modelado. La solución combina técnicas de Procesamiento de Lenguaje Natural (NLP), representación TF-IDF, probabilidades de sentimiento obtenidas con **PySentimiento** y un modelo de Regresión Logística. Asimismo, la variable objetivo clasifica la experiencia en tres grupos: **positiva, neutral y negativa**.

El modelo final alcanzó un Accuracy de 0,8518, un Macro F1 de 0,6955 y un Weighted F1 de 0,8473. La principal mejora frente al enfoque base fue incorporar información de sentimiento y ajustar de forma controlada el peso de la clase neutral, elevando el Macro F1 de validación desde 0,6601 hasta 0,6879. En test, el modelo definitivo obtuvo un Macro F1 de 0,6955.

Además del componente predictivo, el trabajo incorpora un análisis de aspectos: comida, atención, precio, ambiente, tiempo de espera, bebidas, calidad, ubicación y porciones. Así como un recomendador de restaurantes y un dashboard de satisfacción de la experiencia del cliente. De este modo, el proyecto no se limita a producir una predicción, sino que aproxima el modelo a un uso empresarial, permitiendo consultar resultados y convertirlos en información para la toma de decisiones.

2. Introducción

Las plataformas digitales han transformado la forma en que los consumidores interactúan con los establecimientos gastronómicos y han convertido las reseñas (Reviews) en una fuente continua de información sobre la experiencia del cliente.

Actualmente, miles de clientes publican diariamente opiniones y valoraciones que reflejan sus experiencias de consumo por lo cual para un restaurante leer manualmente un gran número de comentarios resulta poco viable. Además, una valoración numérica no siempre explica porque el cliente quedo satisfecho o insatisfecho con la atención brindada.

2.1.1. Problema de negocio

Los restaurantes necesitan comprender de forma rápida y eficiente la percepción de sus clientes para mejorar la calidad de sus servicios ofrecidos. A medida que han pasado los años, los medios digitales han contribuido a la experiencia y satisfacción con la cual se califica a los restaurantes en función a la gran cantidad de reviews de los usuarios en los diversos medios digitales.

Ante esta situación surge la necesidad de desarrollar modelos capaces de interpretar automáticamente las opiniones de los clientes, tratarlas y clasificarlas con la finalidad de calificar la atención y/o experiencia del cliente hacia dicho restaurante.

El presente trabajo de fin master buscara responder a la siguiente pregunta:

¿Es posible utilizar técnicas de Inteligencia Artificial para estimar la satisfacción de clientes de restaurantes peruanos a partir de las reseñas publicadas en plataformas digitales?

A partir de esta problemática, el proyecto busca no solamente desarrollar un modelo capaz de clasificar la experiencia del cliente, sino también transformar los resultados obtenidos en herramientas de apoyo a la toma de decisiones. Para ello, se complementa el modelo predictivo con un análisis de los principales aspectos de la experiencia gastronómica, un sistema de recomendación de restaurantes y un dashboard que facilita la consulta e interpretación de los resultados.

3. Objetivos

3.1.1. Objetivo General

Diseñar una solución analítica basada en técnicas de Procesamiento de Lenguaje Natural e Inteligencia Artificial la cual permita clasificar la experiencia del cliente, identificar factores asociados a la satisfacción y convertir los resultados en herramientas de consulta orientadas a negocio.

3.1.2. Objetivos Específicos

- Preparar y depurar la información de restaurantes y reseñas para garantizar consistencia y calidad.
- Analizar la distribución de valoraciones, categorías, distritos y contenido textual.
- Clasificar el sentimiento de las reseñas en **positivo, neutral y negativo**.
- Comparar alternativas de Machine Learning y seleccionar el enfoque con mejor equilibrio entre rendimiento e interpretabilidad.
- Identificar aspectos concretos de la experiencia del cliente y medir su polaridad.
- Construir un recomendador y un dashboard que faciliten el consumo empresarial de los resultados.

4. Hipótesis

Durante el presente trabajo de fin de master (TFM) vamos evaluar dos posibles enfoques con sus hipótesis para identificar cual es la mejora con respecto a la perspectiva y experiencia que tienen los clientes con respecto a los restaurantes. Procedemos a detallar las hipótesis a analizar:

4.1.1. Hipótesis General

El contenido de las reseñas contiene información suficiente para estimar la satisfacción gastronómica del cliente hacia el restaurante.

4.1.2. Hipótesis Específicas

Como hipótesis específica para el caso de negocio, se plantea que una clasificación en tres estados de experiencia: **positiva, neutral y negativa** resultan con mejor interpretabilidad que intentar predecir exactamente una puntuación de 1 a 5 estrellas otorgada por el cliente.

5. Procedencia del conjunto de datos

La fuente utilizada corresponde al dataset público **Peruvian Food Reviews**. La información se organiza principalmente en dos conjuntos: restaurantes y reseñas. El primero contiene características del establecimiento, como categoría, distrito, coordenadas, número de reseñas y precios; el segundo contiene el texto de la reseña, score y relación con el restaurante.

Fuente de datos: Los datos relacionados al dataset **Peruvian Food Reviews** se encuentran disponibles en una de las plataformas permitidas para datos públicos, en esta oportunidad utilizaremos la siguiente información de reviews disponibles en el siguiente url:

<https://www.kaggle.com/datasets/lazaro97/peruvian-food-reviews/data>

6. Metodología de desarrollo

El presente trabajo de investigación analiza la experiencia y satisfacción de los clientes de restaurantes peruanos a partir de las reseñas publicadas en plataformas digitales. Para abordar este objetivo, se definió una metodología estructurada en diferentes fases que comprende la preparación y tratamiento de los datos, el análisis exploratorio, el procesamiento de las reseñas mediante técnicas de Procesamiento de Lenguaje Natural (NLP), el análisis de sentimiento, la construcción y evaluación de modelos predictivos y el análisis de los principales aspectos relacionados con la experiencia gastronómica. Finalmente, los resultados obtenidos se integraron en componentes de aplicación empresarial, mediante el desarrollo de un sistema de recomendación de restaurantes y un dashboard orientado a facilitar la consulta e interpretación de la información.




Figura 1. Metodología general desarrollada para el análisis de satisfacción gastronómica.

6.1. Preparación de Datos y Análisis Exploratorio

La preparación de datos incluyó revisión de tipos, normalización de variables categóricas, tratamiento de coordenadas, análisis de precios, control de valores atípicos y depuración de reseñas. Durante el desarrollo se comprobó que la información de precios presenta una disponibilidad limitada, por lo que se conservó como información opcional y no se utilizó como requisito general para el modelo.

En el texto se aplicaron tareas de normalización, eliminación de elementos no informativos, tokenización y preparación para TF-IDF. También se analizaron palabras frecuentes, bigramas y trigramas para comprender expresiones recurrentes asociadas a la experiencia gastronómica.

Conjunto	Registros finales	Uso principal
Restaurantes	9871	Características del establecimiento y análisis descriptivo
Reseñas originales	750000	Base textual disponible tras la preparación del proyecto
Reseñas limpias	569877	Base textual disponible tras el análisis exploratorio de los datos
Reseñas para modelado	569102	Entrenamiento y evaluación del modelo

Restaurantes en recomendador	8913	Motor de recomendación
Tabla de aspectos	45327	Agregación restaurante-aspecto

Tabla 1. Resumen de los principales conjuntos de datos utilizados.
Fuente: elaboración propia a partir del dataset Peruvian Food Reviews.

6.2. Análisis de sentimientos y aspectos

6.2.1. Sentimiento mediante NLP

Se incorporó PySentimiento como modelo especializado en español para estimar la polaridad del texto. Sobre el conjunto analizado, la distribución resultante fue 72,76% positiva, 12,76% neutral y 14,48% negativa. La diferencia frente a la distribución derivada directamente del score evidencia que una calificación numérica y el lenguaje utilizado por el cliente no siempre expresan exactamente la misma percepción. Esta información se utilizó no solo como resultado descriptivo, sino también como fuente adicional para el modelo predictivo mediante las probabilidades de sentimiento.




Figura 2. Distribución general del sentimiento identificado en las reseñas mediante PySentimiento.

6.2.2. Análisis de aspectos

El análisis de aspectos identificó diversas menciones distribuidas en nueve dimensiones: **comida, atención, precio, ambiente, tiempo de espera, bebidas, calidad, ubicación y porciones**. Esto permite pasar de una pregunta general acerca si el cliente está satisfecho a una explicación más útil: ¿con qué parte de la experiencia está satisfecho o insatisfecho?

Aspecto	% positivo	Lectura de negocio
Ambiente	88,16%	Principal fortaleza relativa
Comida	78,02%	Alta satisfacción y gran volumen de menciones
Atención	76,64%	Buen desempeño, aunque con margen de mejora
Precio	72,56%	Percepción más heterogénea
Calidad	71,18%	Área sensible por su proporción negativa
Tiempo de espera	62,74%	Principal punto de fricción

Tabla 2. Aspectos relacionados a los reviews.

Fuente: elaboración propia a partir del dataset Peruvian Food Reviews.

El tiempo de espera destaca como la dimensión con menor proporción positiva y mayor concentración de opiniones negativas, lo que constituye una señal accionable para la gestión operativa.




Figura 3. Distribución del sentimiento según los principales aspectos de la experiencia gastronómica.

Los resultados permiten identificar diferencias relevantes entre los componentes de la experiencia gastronómica. El ambiente presenta la mayor proporción de menciones positivas (88,16 %), mientras que el tiempo de espera registra el menor porcentaje positivo (62,74 %) y la mayor proporción de opiniones negativas (21,98 %). Desde una perspectiva de negocio, este análisis permite identificar áreas específicas sobre las cuales priorizar acciones de mejora.

6.3. Modelización y mejoras del modelo

Una vez finalizadas las etapas de preparación de los datos, análisis exploratorio y procesamiento de las reseñas, se desarrolló la fase de modelización con el objetivo de construir un modelo capaz de clasificar automáticamente la experiencia expresada por los clientes.

Durante esta fase se evaluaron diferentes algoritmos, conjuntos de variables y estrategias de optimización. La selección del modelo no se realizó únicamente en función de su porcentaje global de aciertos, sino considerando especialmente su capacidad para distinguir adecuadamente entre experiencias positivas, neutrales y negativas.



Figura 4. Evolución del modelo predictivo. Fuente: elaboración propia.

6.3.1. Definición de la variable objetivo

Para la construcción del modelo predictivo se definió una variable objetivo orientada a representar la satisfacción del cliente de una forma comprensible y útil para el análisis de negocio. A partir de la puntuación asociada a cada reseña, las observaciones fueron agrupadas en tres categorías: **Positiva (POS)**, **Neutral (NEU)** y **Negativa (NEG)**.

Esta transformación permitió simplificar el problema respecto a una clasificación directa de múltiples niveles de puntuación y centrar el análisis en tres estados de experiencia fácilmente interpretables. Desde una perspectiva de negocios, esta clasificación permite diferenciar clientes satisfechos, clientes con una experiencia intermedia y clientes que manifiestan una experiencia desfavorable.

Tras el proceso de preparación se dispuso de **569.102 reseñas válidas para modelado**. La distribución de la variable objetivo mostró un predominio de experiencias positivas, que representan el 77,32 % de las observaciones, frente al 12,65 % de experiencias neutrales y el 10,03 % de experiencias negativas.

Esta distribución evidenció un desbalance entre las clases, aspecto que fue considerado posteriormente tanto en la elección de las métricas de evaluación como durante el proceso de optimización del modelo.

Clasificación	N.º de reseñas	Porcentaje
Positiva	440.003	77,32 %
Neutral	71.994	12,65 %
Negativa	57.105	10,03 %
Total	569.102	100,00 %

Tabla 3. Distribución de la variable objetivo

6.3.2. Preparación de datos para el modelo

Para prepara el contenido textual de las reseñas(reviews) para poder ser utilizado por los algoritmos de Machine Learning, fue necesario transformar el texto en una representación numérica. Para ello se utilizó **TF-IDF (Term Frequency–Inverse Document Frequency)**, técnica la cual permite asignar mayor relevancia a aquellos términos que aportan información diferenciadora dentro del conjunto de reseñas.

Adicionalmente, durante el proceso de experimentación se evaluó la incorporación de información estructurada asociada a las observaciones y posteriormente las probabilidades de sentimiento obtenidas mediante **PySentimiento**. Estas últimas permitieron complementar la información contenida en TF-IDF con una estimación adicional de la orientación positiva, neutral o negativa del lenguaje utilizado por el cliente.

Los datos fueron separados de forma estratificada para conservar la distribución de las tres clases durante el entrenamiento y su evaluación. Asimismo, las decisiones de optimización se realizaron utilizando datos de **validación**, reservándose el conjunto de **test** para la evaluación definitiva del modelo seleccionado.

A continuación, procederemos a mostrar una tabla con el resumen de lo comentado en esta sección de trabajo de fin de master.

Elemento	Configuración final
Observaciones utilizadas	569.102 reseñas
Representación principal	TF-IDF
Información complementaria	Probabilidades NLP
Clases objetivo	POS / NEU / NEG
Matriz final de entrenamiento	455.281 × 30.002
Matriz final de test	113.821 × 30.002

Tabla 4. Preparación de datos para el modelo inicial

6.3.3. Modelo Inicial

Como punto de inicio se estableció un modelo base utilizando **Regresión Logística sobre la representación TF-IDF de las reseñas**, este modelo nos proporcionó una referencia inicial frente a la cual evaluar posteriormente las diferentes estrategias de mejoras.

Clase	Precisión	Recall	F1-Score	N.º observaciones
Negativo (NEG)	0,7346	0,6741	0,7030	9.137
Neutral (NEU)	0,5094	0,2679	0,3511	11.519
Positivo (POS)	0,8887	0,9671	0,9263	70.401
Macro promedio	0,7109	0,6364	0,6601	91.057
Promedio ponderado	0,8252	0,8493	0,8311	91.057

Tabla 5. Métricas relacionadas al modelo inicial

El modelo base de Regresión Logística alcanzó una exactitud global del **84,93 %** y un **Macro F1 de 0,6601 en validación**. Sin embargo, el análisis por clase evidenció diferencias importantes en su capacidad predictiva. Mientras que las experiencias positivas fueron identificadas con un F1 de **0,9263** y las negativas con **0,7030**, la clase neutral presentó un F1 de apenas **0,3511**, principalmente como consecuencia de su bajo nivel de recall (**0,2679**). Esto significa que el modelo identificaba correctamente una proporción reducida de las experiencias neutrales existentes, constituyendo la principal oportunidad de mejora para las siguientes iteraciones.

6.3.4. Comparación de alternativas

A partir del modelo base se evaluaron diferentes alternativas con el objetivo de identificar qué combinación de variables y algoritmo ofrecía una mejora real en la capacidad de clasificación.

En primer lugar, se evaluó la incorporación de **variables estructuradas asociadas a las reseñas**, específicamente la **longitud del texto (review_len)**, la **cantidad de**

interacciones recibidas (likes) y la **plataforma de procedencia (platform)**. El objetivo fue determinar si estas características podían complementar la información textual representada mediante TF-IDF. Sin embargo, su incorporación no produjo una mejora respecto al modelo base, lo que evidenció que añadir información adicional no necesariamente incrementaba la capacidad predictiva.

Posteriormente, se incorporaron las probabilidades de sentimiento generadas mediante PySentimiento. Esta información complementó la representación TF-IDF al aportar una señal adicional sobre la orientación positiva, neutral o negativa del lenguaje utilizado en cada reseña.

También se evaluaron algoritmos alternativos, entre ellos LinearSVC y SGDClassifier. No obstante, ninguno superó el desempeño obtenido por la Regresión Logística combinada con TF-IDF y las probabilidades NLP.

Finalmente, sobre la configuración de mejor desempeño se aplicó una ponderación específica a la clase neutral, con el objetivo de mejorar su detección sin deteriorar excesivamente el comportamiento del resto de clases.

A continuación, procederemos a mostrar una tabla con el resumen de lo comentado en esta sección de trabajo de fin de master.

Configuración	Macro F1	Resultado
Regresión Logística + TF-IDF	0,6601	Modelo base
TF-IDF + variables estructuradas (review_len, likes, platform)	0,6373	No mejora
TF-IDF + probabilidades NLP	0,6703	Mejora
LinearSVC + TF-IDF + NLP	0,6584	Inferior al mejor modelo
SGDClassifier + TF-IDF + NLP	0,6028	Inferior
Regresión Logística + TF-IDF + NLP + ajuste NEU	0,6879	Mejor configuración en validación

Tabla 6. Comparación de alternativas evaluadas

6.3.5. Optimización y mejoras introducidas

A partir de los resultados obtenidos durante la comparación de alternativas, se determinó que la mejora del modelo no dependía solamente de incorporar una mayor cantidad de variables, sino de seleccionar aquellas que aportaban información relevante para distinguir las diferentes categorías de satisfacción.

La primera mejora básicamente consistió en incorporar las **probabilidades de sentimiento obtenidas mediante PySentimiento** como información complementaria a la representación TF-IDF. Esta combinación permitió métricas del modelo ya que permitió incrementar el **Macro F1 de 0,6601 a 0,6703** durante la fase de validación.

Posteriormente, el análisis de los resultados mostró que la **clase neutral (NEU)** continuaba siendo la categoría con mayor dificultad de clasificación por lo cual se evaluaron diferentes ponderaciones para incrementar su importancia durante el entrenamiento. Como resultado la configuración seleccionada asignó un **peso de 1,7 a la clase neutral**, buscando mejorar su identificación sin deteriorar significativamente el comportamiento de las clases positiva y negativa.

Con este ajuste, el modelo alcanzó un **Macro F1 de 0,6879 en validación**, frente al **0,6601 del modelo base**. Esto supone una mejora relativa aproximada del **4,21 %** respecto a la métrica inicial.

Desde una perspectiva de negocio, esta mejora resulta relevante porque permite obtener una clasificación más equilibrada de las experiencias de los clientes. En particular, mejorar la identificación de experiencias neutrales facilita detectar usuarios cuya percepción no es claramente positiva ni negativa y que, por tanto, pueden representar oportunidades para implementar acciones orientadas a mejorar su experiencia.

Etapa	Macro F1 validación	Mejora vs. Base
Modelo base: TF-IDF	0,6601	
+ Probabilidades NLP	0,6703	+1,55 %
+ Ajuste clase NEU (1,7)	0,6879	+4,21 %

Tabla 7. Evolución del modelo respecto a modelo base

6.3.6. Modelo Final Seleccionado

Una vez finalizada la comparación de alternativas y seleccionada la configuración con mejor desempeño durante la fase de validación, se procedió a evaluar el modelo definitivo sobre el **conjunto de test**, reservado previamente para medir su capacidad de generalización sobre observaciones no utilizadas durante el proceso de selección y optimización.

El modelo final corresponde a una **Regresión Logística** que combina la representación textual de las reseñas mediante **TF-IDF**, las **probabilidades de sentimiento obtenidas mediante PySentimiento** y una ponderación específica de **1,7 para la clase neutral (NEU)**.

Sobre el conjunto de test, compuesto por **113.821 reseñas**, el modelo alcanzó una exactitud global (**Accuracy**) de **0,8518**, un **Macro F1 de 0,6955** y un **Weighted F1 de 0,8473**. Estos resultados muestran que el modelo mantiene un buen desempeño global sobre información no utilizada durante su optimización.

El análisis individual de las clases muestra que las experiencias **positivas** presentan el mejor desempeño, alcanzando un F1 de **0,9308**, mientras que las experiencias **negativas** obtienen un F1 de **0,7076**. La clase **neutral** continúa siendo la categoría de mayor dificultad, con un F1 de **0,4481**, debido principalmente a que este tipo de reseñas puede combinar simultáneamente valoraciones favorables y desfavorables.

Desde una perspectiva de negocio, el resultado obtenido permite disponer de una herramienta capaz de clasificar automáticamente grandes volúmenes de reseñas en tres categorías fácilmente interpretables. Esto facilita la identificación de clientes satisfechos, experiencias potencialmente problemáticas y situaciones intermedias que pueden requerir un análisis adicional.

Métrica	Resultado
Accuracy	0,8518
Macro F1	0,6955
Weighted F1	0,8473
F1 – Positivo (POS)	0,9308
F1 – Neutral (NEU)	0,4481
F1 – Negativo (NEG)	0,7076

Tabla 8. Resultados del modelo predictivo final

6.3.7. Inferencia sobre nuevas reseñas

Se implementó un módulo de inferencia para evaluar la aplicabilidad práctica del modelo mediante la clasificación automática de nuevas reseñas(reviews) en categorías positivas, neutrales o negativas. El proceso reutiliza las fases de limpieza, el vectorizador TF-IDF y el análisis de PySentimiento para alimentar un modelo de Regresión Logística accesible a través de una interfaz interactiva desarrollada con ipywidgets.

Predicción de satisfacción de una nueva reseña

Reseña: La comida llegó fría, demoraron demasiado en atendernos y el servicio fue pésimo. No volvería.]

RESULTADO DEL ANÁLISIS

Reseña:
La comida llegó fría, demoraron demasiado en atendernos y el servicio fue pésimo. No volvería.

Predicción final: NEGATIVA

Probabilidades del modelo final

NEGATIVA: 92.60%
NEUTRAL: 7.26%
POSITIVA: 0.14%

Análisis auxiliar - PySentimiento

Sentimiento: NEGATIVA

NEGATIVA: 97.02%
NEUTRAL: 2.57%
POSITIVA: 0.41%

Figura 5. Módulo interactivo de inferencia sobre una nueva reseña

7. Resultados e interpretación del negocio

Una vez finalizadas las etapas de procesamiento, análisis de sentimiento y modelización, los resultados obtenidos fueron analizados desde una perspectiva de negocio con el objetivo de transformar las reseñas(reviews) de los clientes en información útil para la toma de decisiones.

El análisis permite evaluar no solo el nivel general de satisfacción expresado por los usuarios, sino también identificar diferencias según los principales aspectos de la experiencia gastronómica, las categorías de los establecimientos y su ubicación geográfica. Asimismo, se incorporó una valoración ajustada de los restaurantes que considera conjuntamente la puntuación obtenida y el volumen de reseñas disponibles.

De esta manera, los resultados permiten identificar **fortalezas, puntos de fricción y patrones de comportamiento** que pueden servir como apoyo para comprender mejor la experiencia del cliente y orientar posibles acciones de mejora.

7.1.Satisfacción general

El análisis general muestra una percepción predominantemente favorable de la experiencia gastronómica. Del conjunto de reseñas(reviews) analizadas, el **72,76 % fue**

clasificado con sentimiento positivo, mientras que el **14,48 %** presentó **sentimiento negativo** y el **12,76 %** **sentimiento neutral**.

Desde una perspectiva de negocio, el resultado global constituye un primer indicador del nivel de satisfacción, pero no permite determinar por sí mismo las causas que explican las opiniones favorables o desfavorables. Por esta razón, el análisis se complementó posteriormente con la identificación de los aspectos específicos mencionados por los clientes.




Figura 6. Distribución general del sentimiento identificado en las reseñas mediante PySentimiento.

7.2. Análisis de satisfacción por aspectos

Con el objetivo de profundizar en los factores asociados a la experiencia del cliente, se analizaron las menciones correspondientes a nueve aspectos: **comida, atención, precio, ambiente, tiempo de espera, bebidas, calidad, ubicación y porciones**.




Figura 7. Distribución del sentimiento según los principales aspectos de la experiencia gastronómica.

Los resultados muestran diferencias relevantes entre los distintos componentes de la experiencia gastronómica. El ambiente presenta el mayor porcentaje de opiniones positivas, alcanzando un 88,16 %, seguido por bebidas (78,13 %), comida (78,02 %) y ubicación (77,60 %).

En sentido contrario, el tiempo de espera presenta el menor porcentaje de opiniones positivas (62,74 %) y la mayor proporción de sentimiento negativo (21,98 %). También se identifican oportunidades de mejora en aspectos como calidad, porciones y precio, cuyos porcentajes positivos se sitúan por debajo de los obtenidos en comida, atención o ambiente.

Desde una perspectiva empresarial, estos resultados permiten pasar de una valoración general de satisfacción a la identificación de elementos concretos sobre los cuales podrían plantearse acciones de mejora.

7.3. Satisfacción por categoría gastronómica

El análisis por categoría gastronómica permitió identificar diferencias en los niveles de satisfacción según el tipo de establecimiento. Para evitar que categorías con un volumen reducido de opiniones generaran resultados poco representativos, el ranking consideró únicamente aquellas con un mínimo de **1000 reseñas**. Asimismo, para facilitar la interpretación se excluyeron del ranking visual las categorías **“Restaurante (No especificado)”** y **“Otros / No Gastronómico”**.




Figura 8. Top 10 categorías gastronómicas según porcentaje de sentimiento positivo.

Entre las categorías analizadas, la comida peruana presenta el mayor porcentaje de sentimiento positivo, con 83,34 %, seguida por restaurantes saludables (81,93 %) e italianos (80,84 %). También destacan las categorías de Comida Latina / Internacional (79,32 %), Bar / Pub (78,34 %) y Cafetería (78,06 %).

Desde una perspectiva de negocio, estos resultados permiten comparar la percepción de los clientes entre diferentes segmentos gastronómicos. Sin embargo, deben interpretarse como patrones observados en las reseñas disponibles y no necesariamente como una medición exhaustiva de todos los establecimientos pertenecientes a cada categoría.

7.4. Satisfacción por distrito

El análisis geográfico por distritito permitió identificar diferencias en la satisfacción expresada por los clientes según el distrito donde se encuentran los establecimientos. Para mejorar la representatividad de la comparación se estableció nuevamente un umbral mínimo de **1000 reseñas**, resultandos elegibles 40 de los 43 distritos analizados.




Figura 9. Top 10 distritos según porcentaje de sentimiento positivo.

Barranco presenta el mayor porcentaje de sentimiento positivo (79,77 %), seguido de Punta Hermosa (78,25 %), Santa María del Mar (77,62 %) y Chaclacayo (76,26 %). Entre los distritos con un elevado volumen de opiniones también destacan San Isidro (75,94 %) y Miraflores (75,68 %).

Los resultados permiten observar que un mayor volumen de reseñas no implica necesariamente un mayor nivel de satisfacción. Por ejemplo, Miraflores concentra el mayor volumen de opiniones del conjunto analizado, mientras que Barranco obtiene un porcentaje superior de sentimiento positivo.

Desde una perspectiva empresarial, esta información permite analizar diferencias territoriales y puede servir como punto de partida para estudiar características de la oferta gastronómica, comportamiento del consumidor o posicionamiento de establecimientos en determinadas zonas.

7.5. Restaurantes destacados según valoración ajustada

Como punto final, se realizó un análisis de los establecimientos con mejor desempeño utilizando una valoración ajustada, diseñada para considerar conjuntamente la puntuación promedio y el volumen de reseñas disponibles por restaurantes.

Este procedimiento permite reducir el efecto que podría producir una valoración promedio elevada sustentada en un número reducido de opiniones. De esta manera, el ranking busca proporcionar una comparación más equilibrada entre establecimientos con diferentes volúmenes de reseñas(reviews).




Figura 10. Top 10 restaurantes según valoración ajustada.

Entre los restaurantes con mejor valoración ajustada destacan La Masita, Blu Gelateria, Club de Regatas Lima, Aji 555 Real Thai Cuisine e IK Restaurante, entre otros establecimientos incluidos en el ranking.

Este criterio resulta especialmente relevante para la posterior construcción del sistema de recomendación, ya que permite evitar que la selección de restaurantes dependa exclusivamente de su puntuación promedio y aporta una medida de confianza relacionada con la cantidad de información disponible.

8. Aplicación Empresarial

Además del desarrollo y evaluación del modelo predictivo, el proyecto buscó transformar los resultados analíticos obtenidos en herramientas que faciliten su utilización por parte de usuarios sin conocimientos técnicos especializados. Para ello, se desarrollaron dos componentes complementarios: **un sistema de recomendación de restaurantes y un dashboard interactivo para el análisis de la satisfacción gastronómica.**

Estos componentes permiten trasladar los resultados obtenidos durante las etapas de análisis de sentimiento, análisis de aspectos y procesamiento de las reseñas (reviews) hacia un entorno de consulta más cercano a una aplicación empresarial. De esta manera, el usuario puede introducir determinados criterios, consultar indicadores y obtener resultados sin necesidad de interactuar directamente con el código o con los modelos desarrollados.

8.1. Sistema de recomendación de restaurantes

Durante esta sección se explicará la aplicación empresarial: **el sistema de recomendación.** Dicho sistema fue desarrollado con el objetivo de transformar los resultados obtenidos durante el análisis en una herramienta que permita al usuario identificar restaurantes de acuerdo con diferentes criterios de búsqueda.

El recomendador permite seleccionar características como distrito, categoría gastronómica, nivel de precio y aspecto de la experiencia, además de establecer un

número mínimo de reseñas y menciones. A partir de estos criterios, el sistema filtra los establecimientos disponibles y genera un ranking de recomendaciones.

Criterio	Utilidad para el usuario
Distrito	Limitar la búsqueda geográficamente
Categoría	Seleccionar el tipo de restaurante
Nivel de precio	Adaptar resultados al rango económico
Aspecto	Priorizar comida, atención, ambiente, etc.
Mínimo de reseñas	Evitar recomendaciones con poca evidencia
Mínimo de menciones	Asegurar suficiente información sobre el aspecto
N.º de resultados	Definir cuántas recomendaciones mostrar

Tabla 10. Criterios de búsqueda del recomendador

Para evitar que restaurantes con una puntuación elevada pero sustentada en pocas opiniones aparezcan automáticamente en las primeras posiciones, se incorporó una valoración ajustada (Weighted Rating) que considera conjuntamente la valoración promedio del establecimiento y la cantidad de reseñas disponibles. De esta forma, el ranking proporciona mayor estabilidad a establecimientos cuya valoración se encuentra respaldada por un volumen suficiente de opiniones.

Recomendador de restaurantes

Selecciona tus preferencias para obtener recomendaciones personalizadas.

Distrito:
 Categoría:
 Precio:
 Valor más:
 Mín. reviews: 10
 Mín. menciones: 3
 Resultados: 10

 Se encontraron 10 recomendaciones.

	Restaurante	Categoría	Distrito	Valoración promedio	Valoración ajustada	N.º de reseñas	Precio promedio	Nivel de precio	Puntuación final
0	IK Restaurante	Peruana	MIRAFLORES	4.64	4.62	1028	S/ 276.50	Lujo	0.923
1	Cebichería La Mar	Peruana	MIRAFLORES	4.54	4.53	3281	S/ 89.00	Premium	0.907
2	Restaurante Statera	Peruana	MIRAFLORES	4.77	4.46	65	S/ 180.00	Lujo	0.892
3	Huaringas Bar	Peruana	MIRAFLORES	4.53	4.45	254	S/ 43.50	Intermedio	0.891
4	Delizia Cafe	Peruana	MIRAFLORES	4.88	4.39	33	Sin información	Sin información	0.878
5	mó bistró	Peruana	MIRAFLORES	4.52	4.38	114	S/ 18.00	Económico	0.876
6	Artesano Bar	Peruana	MIRAFLORES	4.96	4.36	24	S/ 39.50	Intermedio	0.872
7	Puerto Med Restaurante	Peruana	MIRAFLORES	4.60	4.34	52	S/ 35.50	Intermedio	0.868
8	Mayta Restaurante	Peruana	MIRAFLORES	4.36	4.33	384	S/ 124.50	Lujo	0.866
9	Maikali Poke Perú	Peruana	MIRAFLORES	5.00	4.31	17	S/ 45.50	Intermedio	0.862

Figura 11. Ejemplo de funcionalidad del Recomendador

8.2. DashBoard de satisfacción gastronómica

Como complemento al sistema de recomendación, se desarrolló un Dashboard interactivo orientado a facilitar la consulta de los principales indicadores obtenidos durante el análisis de las reseñas.

El Dashboard permite visualizar la satisfacción desde diferentes perspectivas y aplicar filtros para analizar segmentos específicos de la información. Entre sus principales funcionalidades se encuentran la consulta de la distribución general del sentimiento, el análisis de satisfacción por distrito y categoría gastronómica, la evaluación del

sentimiento asociado a los diferentes aspectos de la experiencia y la identificación de restaurantes destacados.

Su principal finalidad es facilitar la interpretación de los resultados por parte de usuarios de negocio, evitando que sea necesario revisar directamente las estructuras de datos, el código o las salidas técnicas utilizadas durante el desarrollo del proyecto.

Explora los principales resultados obtenidos a partir del análisis de reseñas de restaurantes.




Figura 12. Dashboard interactivo para el análisis de la satisfacción gastronómica

9. Conclusiones

El presente Trabajo Fin de Máster permitió desarrollar una solución analítica para estudiar la satisfacción y experiencia de los clientes de restaurantes peruanos a partir de las reseñas publicadas en plataformas digitales. A lo largo del proyecto se combinaron técnicas de preparación de datos, Procesamiento de Lenguaje Natural, análisis de sentimiento, Machine Learning y análisis de aspectos, complementándose posteriormente con herramientas orientadas a facilitar la utilización de los resultados. Con respecto a lo mencionado puede mencionar lo siguiente:

- El contenido de las reseñas es clave para analizar y clasificar la satisfacción del cliente de forma sólida.
- La combinación de TF-IDF y PySentimiento mejoró la capacidad predictiva y el desempeño del modelo final.
- Más variables no garantizan mejoras, por ejemplo, datos como la longitud de la reseña o la plataforma no aportaron valor al modelo base.
- El ajuste de la clase neutral y la información de sentimiento sí generaron una mejora real en la clasificación.
- Las opiniones neutrales son el mayor desafío, a pesar del excelente rendimiento del modelo al identificar experiencias positivas y negativas.
- El análisis de aspectos detectó fortalezas y debilidades, posicionando al ambiente como el punto fuerte y al tiempo de espera como la mayor oportunidad de mejora.
- Se crearon herramientas para la toma de decisiones: un sistema de recomendación y un Dashboard interactivo.

De cara a mejoras futuras, se plantea evaluar modelos de lenguaje más avanzados que permitan mejorar especialmente la identificación de experiencias neutrales y el análisis

de sentimiento por aspecto. Asimismo, sería posible incorporar periódicamente nuevas reseñas, enriquecer el sistema de recomendación con información adicional y evolucionar el prototipo hacia una aplicación empresarial mediante el despliegue del modelo como servicio o API, incorporando mecanismos de monitorización, actualización y reentrenamiento.

En conclusión, se puede mencionar que la experiencia de los clientes a través de los reviews es de vital importancia dentro del turismo gastronómico ya que nos permite tomar estrategias y acciones para un mayor crecimiento de la gastronomía local.

10. Anexos

10.1. Código fuente y material de desarrollo

El código fuente desarrollado durante el presente Trabajo Fin de Máster se encuentra disponible en un repositorio de GitHub creado para facilitar su consulta y revisión.

El repositorio contiene el código correspondiente a las principales fases del proyecto, incluyendo preparación y análisis de datos, Procesamiento de Lenguaje Natural, análisis de sentimiento, modelización y optimización, análisis de aspectos, sistema de recomendación y Dashboard.

Como material complementario, se adjunta también la versión HTML del notebook final, que permite consultar el desarrollo completo del proyecto junto con los resultados obtenidos sin necesidad de ejecutar el código.

Repositorio del proyecto: <https://github.com/miguelchavez26/TFM-Satisfaccion-Restaurantes-Peru>

Notebook final (HTML): TFM_Satisfaccion_Restaurantes_Peru_Miguel_Chavez.html